Uniwersytet Jagielloński Wydział Matematyki i Informatyki INSTYTUT INFORMATYKI I MATEMATYKI KOMPUTEROWEJ Studia dzienne

Nr indeksu: 1104482

Marta Szynczewska

Zbiór i ocena jakości i aktualności narzędzi do przewidywania struktury drugorzędowej RNA

Opracowano zgodnie z Ustawą o prawie autorskim i prawach pokrewnych z dnia 4 lutego 1994 r. (Dz.U. 1994 nr 24 poz. 83) wraz z nowelizacją z dnia 25 lipca 2003 r. (Dz.U. 2003 nr 166 poz. 1610) oraz z dnia 1 kwietnia 2004 r. (Dz.U. 2004 nr 91 poz. 869)

Spis treści

Wstęp teoretyczny	3
RNA – definicja	3
Struktury RNA	3
Metody	6
Afold	6
Carnac	7
CentroidFold	8
CentroidHomfold	10
ContraFold	12
DotKnot	13
HotKnots	13
TurboKnot	16
CMfinder	17
CRWrnafold	18
CyloFold	19
Mastr	19
MaxExpect	21
PPfold	24
RNAwolf	25
Sfold	25
taveRNA	25
TurboFold	25
Opcje narzędzi	26
Podsumowanie	30
Rihliografia	31

Wstęp teoretyczny

RNA – definicja

RNA, zwane inaczej kwasem rybonukleinowym, to długa liniowa makrocząsteczka polinukleotydowa. Nukleotydy połączone są wiązaniami fosfodiestrowymi 3' → 5'. Każdy nukleotyd zbudowany jest z jednostki cukrowej, przynajmniej jednej reszty fosforanowej oraz zasady azotowej. W przypadku RNA resztą cukrową jest ryboza oraz wyróżniamy cztery podstawowe zasady azotowe: adeninę oznaczaną literą A, guaninę (G), cytozynę (C) i uracyl (U).

Cząsteczki RNA występują głównie w postaci pojedynczej nici, jednakże łańcuch RNA może się zwinąć i stworzyć strukturę *spinki do włosów* o budowie dwuniciowej helisy. W tych strukturach adenina tworzy pary z uracylem, a guanina z cytozyną.

Struktury RNA

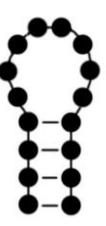
 a) Pierwszorzędowa
 Strukturę pierwszorzędową RNA definiujemy jako ciąg nukleotydów ułożonych jeden po drugim.

$$A_TG^{A}^{CG}T_{A}^{CG}$$

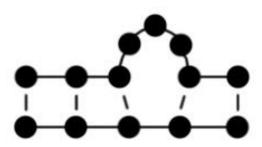
b) Drugorzędowa

Strukturę drugorzędową RNA definiujemy jako położenie ciągu nukleotydów na płaszczyźnie. Strukturami, jakie możemy zauważyć są m.in. spinki do włosów, wybrzuszenia, pętle wewnętrzne, węzły, pseudowęzły oraz odcinki dwuniciowe.

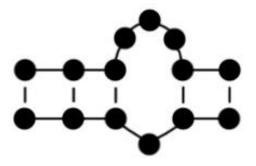
Spinka do włosów (hairpin) - struktura składająca się z części dwuniciowej oraz pętli zewnętrznej.



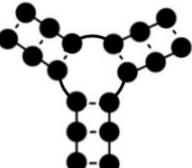
Wybrzuszenie (bulge loop) - struktura składająca się z przynajmniej dwóch niesparowanych nukleotydów tylko na jednej z nici.



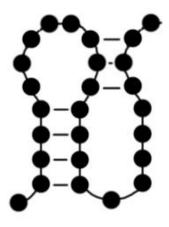
Pętla wewnętrzna (internal loop) - struktura składająca się z niesparowanych nukleotydów na obu niciach pomiędzy dwoma odcinkami podwójnej helisy.



Węzeł (junction) - rozgałęzienie przynajmniej trzech odcinków podwójnej helisy.

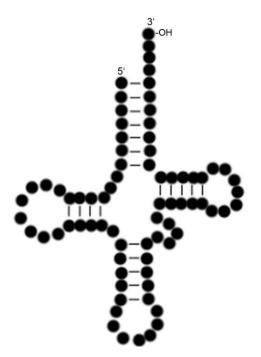


Pseudowęzeł (pseudoknot) - struktura opierająca się na oddziaływaniach pomiędzy nukleotydami wchodzącymi w skład innej struktury, np. spinki do włosów, a innymi nukleotydami.



Często zdarza się, że zasady nie tworzą idealnych par typu Watsona-Cricka. Uracyl może tworzyć parę z guaniną, ponieważ wiązania występują wodorowe pomiędzy N3 uracylu i C6 guaniny oraz C2 uracylu i N1 guaniny. Jednakże para guaniny i cytozyny jest od niej silniejsza.

Najbardziej znanym przykładem struktury drugorzędowej RNA jest tRNA, które wyglądem przypomina liść koniczyny.



Metody

Afold

Metoda Afold powstała między 2003 a 2006 rokiem. Autorem narzędzia jest Aleksey Ogurtsov. Służy ona głównie do przewidywania struktury drugorzędowej pętli wewnętrznych RNA dla sekwencji o długości nie większej niż 28 000 nukleotydów. Przetwarzanie tak długiej sekwencji przy użyciu tego algorytmu trwa ok. 28 godzin na komputerze z 2GB RAM.

W algorytmie wykorzystywany jest model najbliższego sąsiada NNM (nearestneighbor model) z założeniem, że kara dla pętli wewnętrznej zależy od dwóch zmiennych:

$$F(s,d) = f_{Len}(s) + f_{Diff}(d),$$

gdzie s jest ilością niesparowanych nukleotydów w pętli, a d jest różnicą w długości pomiędzy dwoma niesparowanymi regionami tworzącymi pętlę. W celu oceny poprawności pętli, algorytm korzystać z listy kandydatów.

Złożoność czasowa algorytmu jest równa O(M*log²L), gdzie L oznacza długość sekwencji. W porównaniu z Mfold oraz ZUCKER, Afold wypada znacznie lepiej. Przede wszystkim jest szybszy już w etapie wypełniania macierzy oraz nie posiada ograniczenia ilości nukleotydów w pętli.[4]

Afold jest dostępny za darmo do pobrania z serwera ftp: ftp://ftp.ncbi.nlm.nih.gov/pub/ogurtsov/Afold/. Po przejściu na serwer otrzymujemy widok jak przedstawiony obok.

Mamy do wyboru pliki instalacyjne na system Windows i Linux. Jednakże w obecnej chwili pliki dedykowana dla Windows są niekompletne.



Ryc.1. Zawartość serwera ftp.

Carnac

Głównym celem metody Carnac jest przewidywanie konserwatywnych elementów struktury drugorzędowej rodzin homologicznych niekodującego RNA.[38] W metodzie tej nie jest wymagane wcześniejsze dopasowanie sekwencji, dlatego idealnie nadaje się do danych posiadających niskie podobieństwo struktur pierwszorzędowych. Trzy podstawowe komponenty metody to: termodynamiczna minimalizacja energii, dopasowanie filogenetyczne oraz konserwacja sekwencji. Dodatkowo wykluczamy wyizolowane pary i pseudowęzły.

Algorytm składa się z trzech kroków:

Krok pierwszy to wyłonienie wszystkich potencjalnych łodyg o niskim poziomie energii swobodnej dla wszystkich sekwencji. Poszukiwanie jest realizowane za pomocą programowania dynamicznego.

Krok drugi polega na analizie wszystkich możliwych par sekwencji i tworzeniu struktury złożonej właśnie z danej pary. Aby dwie sekwencje uznać za parę muszą one spełnić warunki. W obu sekwencjach powinny znajdować się analogiczne dobrze zakonserwowane regiony oraz muszą zawierać co najmniej jedną mutację kompensacyjną.

Krok trzeci to tworzenie grafu macierzystego złożonego na podstawie relacji między najbardziej wiarygodnymi sekwencjami.

Istnieją dwa sposoby na użycie Carnac: pobranie i instalacja oprogramowania na własnym komputerze lub online na stronie: http://bioinfo.lifl.fr/RNA/carnac/. Obie wersje są darmowe, bez rejestracji. Dane wejściowe muszą być podane w formacie FASTA, natomiast wynik otrzymujemy w kilku formatach: Connest file (CT), PostScript oraz w formie graficznej. Każdemu procesowi zostaje nadany unikalny numer ID, pod którym zapisywane są operacje. Czas oczekiwania zależy od długości sekwencji. Jeśli długość jest mniejsza niż 300 nukleotydów to zajmuje to kilka sekund, dla większych danych czas wydłuża się do kilku minut.[6]



| New | New

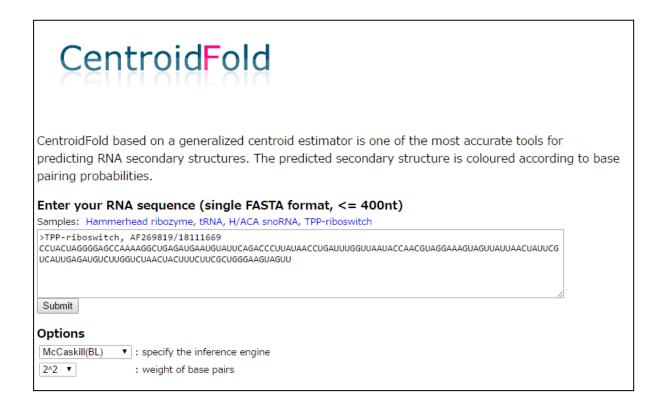
Ryc.2. Strona domyślna Carnac.

Ryc.3. Strona wynikowa Carnac.

CentroidFold

Narzędzie CentroidFold może być użyte do przewidywania struktury drugorzędowej RNA jednej sekwencji lub dopasowani wielu sekwencji RNA. Jest to możliwe dzięki opracowaniu algorytmu opartego na γ-centroid estymatorze. Estymator ten to pewnego rodzaju sposób dekodowania bazujący na teorii decyzji statystycznej.[7] Dzięki zastosowaniu estymatora metoda jest bardzo precyzyjna.[39]

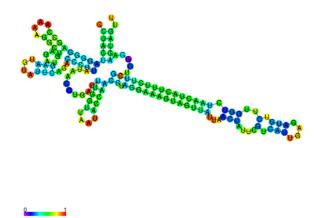
CentroidFold dostępny jest wyłącznie online na stronie: http://rtools.cbrc.jp/centroidfold/. Jako dane wejściowe akceptowalne są dwa formaty: FASTA dla jednej sekwencji oraz format Clustal W dla dopasowani wielu sekwencji RNA. Nie ma potrzeby zaznaczania jaki format wybrano, ponieważ jest on automatycznie wykrywany.[7] Interfejs jest bardzo prosty i przejrzysty.



Ryc.4. Strona domyślna CentroidFold.

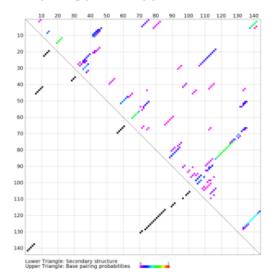
Wyniki otrzymujemy w kilku formatach, w tym także graficznych z odpowiednim kolorowaniem. Jak widać na poniższych ilustracjach mamy do wyboru formaty zapisu do pliku: TEXT, jako obrazek PNG, PDF lub z rozszerzeniem .eps.

Secondary structure



Download: TEXT PNG PDF EPS

Base pairing probability plot



Download: TEXT PNG PDF EPS

Download:TEXT (Secondary structure) is a dot-bracket format with a fasta-like header line, indicating a secondary structure.

In this format, each dot represents an unpaired base, opening and closing brackets represent a base pair.

Download:TEXT (Base pairing probability plot) contains base-pairing probabilities more than "weight of base pairs" in blank delimited format.

```
pos1 nt1 pair-pos11:prob11 pair-pos12:prob12 ...
pos2 nt2 pair-pos21:prob21 pair-pos22:prob22 ...
:
```

 ${\sf pos1,pos2}$ are sequence positions in 1-based coordinate.

nt1,nt2 are nucleotides.

pair-pos11,pair-pos12 ... are sequence positions of pairing partners in 1-based coordinate.

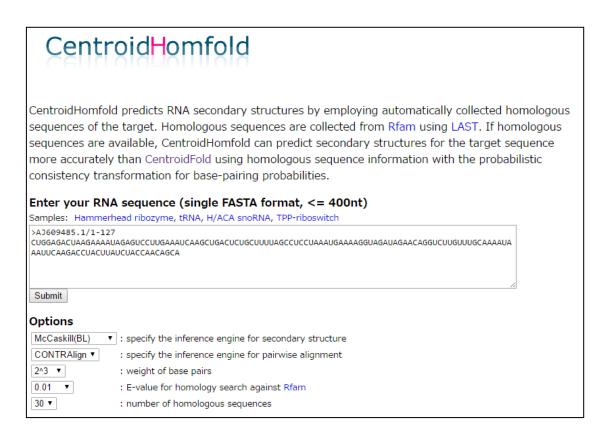
pron11,prob12 \dots are base pairing probabilities.

CentroidHomfold

Narzędzie pochodzi z tego samego serwera co CentroidFold. Jednakże sposób działania jest znacznie inny. Przy wyznaczaniu struktury drugorzędowej RNA, CentroidHomfold uwzględnia informacje o homologach danej sekwencji.[8] Sekwencje homologiczne pobierane są automatycznie z bazy danych Rfam przy użyciu LAST. Użycie tych dodatkowych informacji daje CentroidHomfold znaczną przewagę nad CentroidFold w dokładności przewidywania struktury. [40] Ponadto narzędzie wykorzystuje również znany nam z poprzedniej metody γ-centroid estymator.

Cele narzędzia możemy podzielić na trzy części. Pierwszy z nich to znalezienie struktury drugorzędowej danej sekwencji RNA. Drugi to znalezienie sekwencji homologicznych do podanej sekwencji oraz trzeci, czyli znalezienie struktur drugorzędowych homologów.

CentroidHomfold dostępny jest online za darmo pod adresem: http://rtools.cbrc.jp/centroidhomfold/. Jako dane wejściowe akceptowane są pliki formacie FASTA. Natomiast wynik otrzymujemy W kilku formatach przedstawionych poniżej.



Ryc.5. Strona domyślna CentroidHomfold.

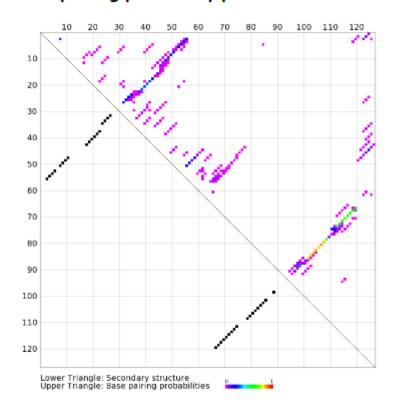
Secondary structure





Download: TEXT PNG PDF EPS

Base pairing probability plot



Download: TEXT PNG PDF EPS

ContraFold

Metoda ContraFold wypełnia lukę pomiędzy metodami probabilistycznymi a termodynamicznymi udowadniając, że procedury uczenia statystycznego mogą stanowić alternatywę dla empirycznego pomiaru parametrów termodynamicznych do przewidywania struktury drugorzędowej RNA. ContraFold oparty jest na warunkowych modelach logarytmiczno-liniowych, probabilistycznych modelach uogólniających stochastyczną gramatykę bezkontekstową (SCFGs) poprzez funkcje wyższych punktacji. Dzięki temu narzędzie osiąga wysoką dokładność predykcji pojedynczego ciągu.[5]

Istnieją dwie opcje użytkowania narzędzia. Po pierwsze, pakiet oprogramowania możemy ściągnąć na swój komputer i zainstalować. Mamy do wyboru dwie wersje – starszą v1.00 lub nowszą v2.00. Obie wersje zaimplementowane są w języku programowania C++ i są darmowe. Jednakże instalacja możliwa jest tylko na systemie Linux.

Drugą opcją jest wersja online na stronie: http://contra.stanford.edu/contrafold/. Formatem wejściowym jest FASTA, a wyjściowym BPSEQ. Mamy też możliwość bezpośredniego przesłania wyników na podanego maila. Wartą uwagi jest opcja wyboru pod względem parowania się nukleotydów. Możemy użyć opcji domyślnej typu Watsona-Cricka lub dopuścić parowanie się wszystkich możliwych.[41]

CONTRAfold
CONditional TRAining for RNA Secondary Structure Prediction
Home CONTRAlign CONTRAFOLD CONTRAST
[Description Server Download RAF FAQ Links]
You may use the CONTRAfold server to predict RNA secondary structures, input to the server consists of a single FASTA format sequence, up to 1000 characters in length.
For larger sequences, CONTRAfold may be executed on your local machine (see download page). (See the FAQ for a note regarding multiple sequence prediction with CONTRAfold.)
The email server is currently down. Please use the web interface.
Step 1: Choose either of two input methods.
(a) Enter FASTA format sequence (see example)
Clear input
OR
(b) Upload FASTA format text file: Wybierz plik.] Nie wybrano pliku
Step 2: Choose either of two output methods.
Send results to e-mail address:
Type your e-mail address: Re-type your e-mail address:
OR
Send results to web browser.
Step 3: Select advanced options (optional).
Output format: Parenthesized BPSEO
Base-pairing: Bysety (Mounty complementary base pairs (AU, CG, GU) Allow all possible base pairs
Step 3: Click submit!
Run CONTRAfold! Clear form
Site design by Chuong Do. Artwork by Marina Sirota.
Comments? Questions? Send us feedback.

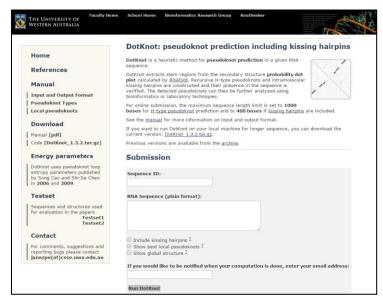
Ryc.6. Strona domyślna ContraFold.

DotKnot

Znalezienie struktury pseudoowęzłów o minimalnej energii swobodnej jest problemem NP-zupełnym. Jednym ze sposobów na przewidywanie struktur drugorzędowych pseudowęzłów jest podejście heurystyczne polegające na poszukiwaniu w sekwencji potencjalnych kandydatów na pseudowęzły i późniejsza ich weryfikacja. DotKnot wybiera podejrzane regiony i składa je w jeden konstrukt. Metoda skuteczna jest dla długich sekwencji oraz znajduje pseudowęzły z większą dokładnością niż pozostałe algorytmy aktualnie dostępne. DotKnot przewiduje również pseudowęzły typu H, których odcinki mogą być poprzerywane przez wybrzuszenia lub pętle wewnętrzne.[13]

Narzędzie jest dostępne online pod adresem: http://dotknot.csse.uwa.edu.au/ lub do pobrania na swój komputer. Obie opcje są darmowe.

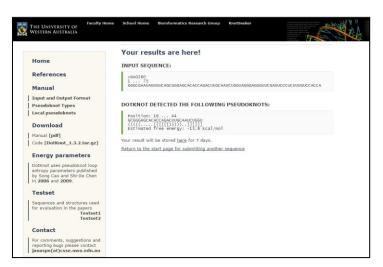
Formatem wejściowym danych jest sekwencja w formacie FASTA.[42]



Ryc.7. Strona domyślna DotKnot.

Wyniki otrzymujemy w notacji dot-bracket.

Wykryte pseudowęzły są następnie weryfikowane za pomocą technik laboratoryjnych.



Ryc.8. Strona wynikowa DotKnot.

HotKnots

HotKnots jest kolejną metodą heurystyczną służącą do przewidywania struktury drugorzędowej RNA z pseudowęzłami lub bez nich. Została ona zaimplementowana przez Jihong Ren w 2005 roku. Narzędzie bada wiele alternatywnych struktur stosując algorytm minimalizacji energii swobodnej, sprawdza potencjalnych kandydatów do tworzenia pseutowęzła i buduje większą strukturę łącząc kandydatów. Tworzone jest to na wzór drzewa, w którym każdy węzeł to jedna substruktura, zwana w tym algorytmie "hotspot". Wybieranie odpowiednich hotspotów odbywa się dzięki programowaniu dynamicznemu.

Metoda jest dostępna za darmo online na stronie: http://www.cs.ubc.ca/labs/beta/Software/HotKnots/. Tam również można pobrać pliki instalacyjne na swój komputer. Mamy do wyboru dwie wersje – starszą 1.0 oraz nowszą 2.0. Wersja 2.0 jest do użycia również online.

Jako dane wejściowe należy wpisać sekwencję ułożoną od 5' do 3'. Ponadto mamy do wyboru 4 modele z różnymi parametrami, na podstawie których zostanie przeprowadzona predykcja. Tutaj również istnieje możliwość przesłania wyników bezpośrednio na podanego w formularzu maila.[43]



Ryc.9. Strona domyślna HotKnots.

Natomiast wyniki otrzymujemy w notacji dot-bracket.

```
[ RNAsoft Home | PairFold | CombFold | RNADesigner | HotKnots ]
HotKnots - results
[ New Run | Help ]
  Input
    Sequence [ ? ]:
      5'- GGCGCGCACCGUCCGCGGAACAACGG -3'
    Model and parameters [ ? ]:
       The model is Dirks & Pierce, the set of parameters is DP09.
    The temperature is fixed to 37°C.
  Output: 9 secondary structures sorted according to MFE:
    Structure 1 and its minimum free energy [ ? ]:
      5'- ..((((((..[[[])))))......]]]]] -3' -8.02 kcal/mol
      Note: You may visualize this structure by copying and pasting the sequence and secondary structure in Pseudoviewer.
    Structure 2 and its minimum free energy [ ? ]:
      5'- ..((((((....))))))........ -3' -5.14 kcal/mol
      Note: You may visualize this structure by copying and pasting the sequence and secondary structure in <u>Pseudoviewer</u>.
    Structure 3 and its minimum free energy [ ? ]:
      5'- .(((.....[[[[.)))......]]]]] -3' -4.61 kcal/mol
      Note: You may visualize this structure by copying and pasting the sequence and secondary structure in Pseudoviewer.
    Structure 4 and its minimum free energy [ ? ]:
      5'- .....(((.[[[))).....]]] -3' -3.14 kcal/mol
      Note: You may visualize this structure by copying and pasting the sequence and secondary structure in <u>Pseudoviewer</u>.
    Structure 5 and its minimum free energy [ ? ]:
      5'- ((.....))..(((.....))) -3' -2.03 kcal/mol
      Note: You may visualize this structure by copying and pasting the sequence and secondary structure in <u>Pseudoviewer</u>.
    Structure 6 and its minimum free energy [ ? ]:
      5'- .....(((....)))...... -3' -1.77 kcal/mol
      Note: You may visualize this structure by copying and pasting the sequence and secondary structure in Pseudoviewer.
```

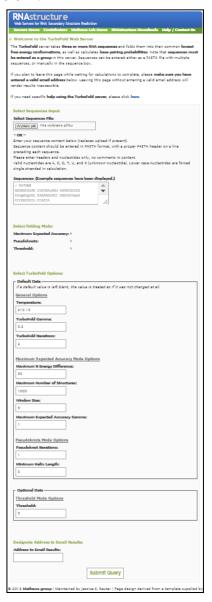
Ryc.10. Strona wynikowa HotKnots.

TurboKnot

Metoda służy do przewidywania struktury drugorzędowej RNA, w tym pseudowęzłów zachowanych w obrębie wielu sekwencji. TurboKnot potrafi przewidzieć z dokładnością wynoszącą 80%, co jest bardzo dobrym wynikiem w porównaniu do innych metod. Opiera się na wyborze konformacji o najniższej energii swobodnej z wielu sekwencji.[35]

TurboKnot jest częścią większego oprogramowania RNAstructure, jest to jeden z kilku podprogramów. Aby pobrać go na swój komputer należy pobrać całą paczkę oprogramowania ze strony RNAstructure: http://rna.urmc.rochester.edu/RNAstructure.html. Natomiast jeśli chcemy go użyć online jako samodzielnego programu należy udać się pod adres: http://rna.urmc.rochester.edu/RNAstructure Web/Servers/TurboFold/TurboFold.html.

Plik wejściowy to co najmniej trzy sekwencje w formacie FASTA w jednym pliku. Dodatkowo momy możliwość wyboru jednego z trzech trybów oraz wiele (temperatura, opcji min długość helixy, Plik itp.). wyjściowy możemy pobrać w formatach: SVG, PDF, JPG, PostScript, CT.[44]



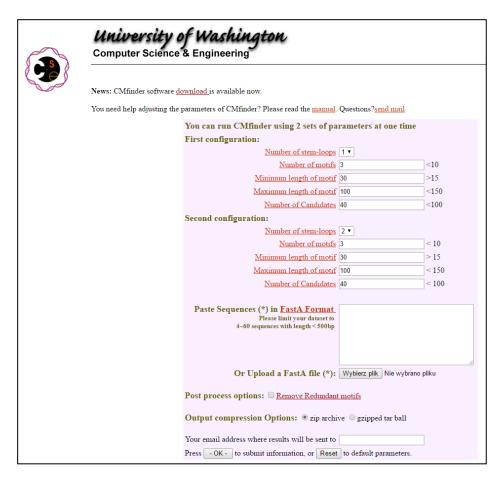
Ryc.11. Strona domyślna TurboKnot (z lewej).

Ryc.12. Strona wynikowa TurboKnot (z prawej).

CMfinder

CMfinder to nowa metoda pozwalająca na przewidywanie motywów RNA w niedopasowanych sekwencjach. Do opisu motywów wykorzystywany jest model kowariancji i framework Bayesa. Może być również wykorzystywany do poszukiwania homologów aby udoskonalić modele struktur na podstawie znalezionych sekwencji homologicznych. Dzięki temu uzyskano bardzo dokładne modele kowariancji znanych motywów RNA na podstawie niewielkiej liczby powiązanych sekwencji, które znaleziono u odległych homologów.[9]

Narzędzie możemy używać lokalnie na swoim komputerze. Aktualnie dostępna jest wersja 0.2, którą możemy ściągnąć ze strony: http://bio.cs.washington.edu/CMfinderWeb/CMfinderDownload.pl. Przed pobraniem konieczne jest wypełnienie formularza z danymi. Alternatywą jest wersja online dostępna pod adresem: http://bio.cs.washington.edu/CMfinderWeb/CMfinderInput.pl. Sekwencję podajemy w formacie FASTA, a wynik otrzymujemy zapakowane w archiwum. Niestety metoda ma ograniczenie do 60 sekwencji o długości maksymalnej do 500 nukleotydów.[45]



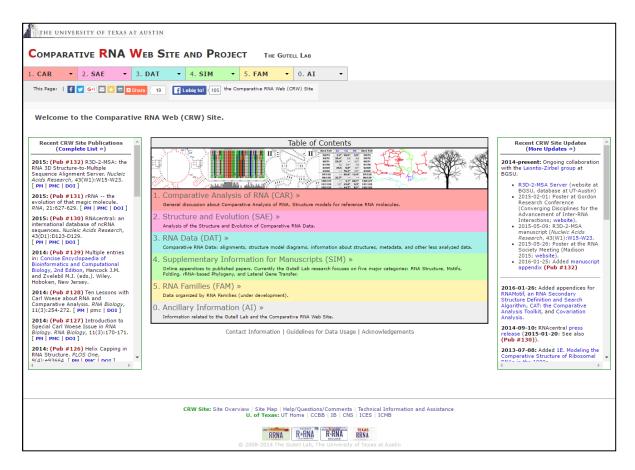
Ryc.13. Strona domyślna CMfinder.

CRWrnafold

CRWrnafold jest pewnego rodzaju bazą zawierającą zróżnicowaną kolekcję modeli struktur drugorzędowych przewidywanych na podstawie analizy porównawczej dla różnych grup filogenetycznych – 5S, 16S, 23S, tRNA, I i II grupa intronów.

Obecnie jest dostępnych ok 1092 struktur drugorzędowych z dokładnością około 97%, natomiast sekwencji jest ponad 54 000.[9]

Baza dostępna jest online pod adresem: http://www.rna.ccbb.utexas.edu/DAT/3C/Structure/index.php lub możemy ją pobrać na swój komputer. Nie musimy pobierać od razu całej bazy, możemy wybrać to, co nas interesuje i pobrać tylko konkretne fragmenty.[46]



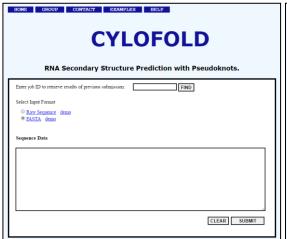
Ryc.14. Strona domyślna CRWrnafold.

CyloFold

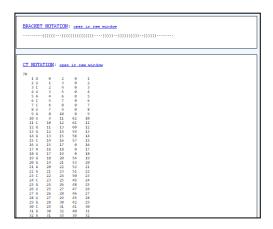
Metoda CyloFold służąca do przewidywania struktur drugorzędowych z uwzględnieniem pseudowęzłów. Główną jej zaletą jest to, że algorytm nie ma ograniczeń pod względem złożoności pseudowęzłów.

Algorytm początkowo tworzy listę wszystkich możliwych helis z ponad 3 pb. Helisy mogą się parować zgodnie z teorią Watsona-Cricka lub GU-wobble. Predykcja odbywa się poprzez wybór najlepiej punktowanych struktur po 50 krokach symulacji. Wynik jest ustalany jako suma wkładu energii swobodnej z już wprowadzonych helis.

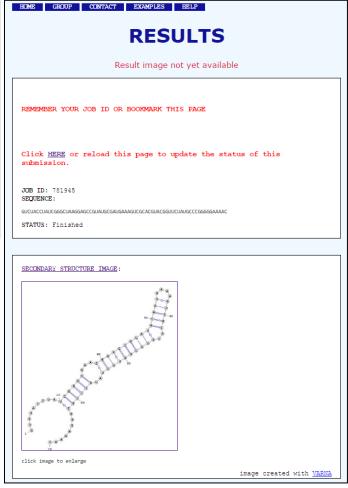
Dostęp do metody możliwy jest tylko online na stronie: https://cylofold.ncifcrf. gov/cylofold-0.1/sequenceJob/create. Główny algorytm zaimplementowany jest w C++, natomiast serwer internetowy zaimplementowano przy użyciu Grails frameworku, który jest oparty na Groovy.[11] Aby wygenerować obraz przewidywanej struktury uruchamiany jest program VARNA. Wyniki są tymczasowo przechowywane w relacyjnej bazie danych. Sekwencję wkleja się w formacie FASTA lub Raw i trzeba zaznaczyć który format się wybiera.[47]



Ryc.15. Strona domyślna CyloFold (powyżej).



Ryc.15. Strona wynikowa CyloFold (powyżej).



Ryc.16. Strona wynikowa CyloFold (powyżej).

MASTR

Algorytm MASTR (Multiple Aligment of STrustural RNAs), jak sama nazwa wskazuje, służy do przewidywania struktur drugorzędowych dla dopasowań wielu sekwencji RNA. Do tego celu używa Markowskich łańcuchów Monte Carlo, iteracyjnie poprawia dopasowanie sekwencji i przewidywanie struktury dla zbioru sekwencji RNA. Wykorzystywane są również ukryte modele Markova (HMM) oraz suma par. Metoda wykazuje wysoką dokładność i wydajność obliczeniową.

Technika optymalizacji inspirowana jest fizycznym procesem wyżarzania, w którym to powolne chłodzenie materiału powoduje powstawanie struktury krystalicznej. Ogólnie im mniejsza energia tym układ stabilniejszy. Analogicznie jest tym algorytmie, tworzy się symulację by uniknąć minimów lokalnych i uzyskać minimum globalne na końcu procesu. Symulowane wyżarzanie może być stosowane do zminimalizowania kosztów funkcji i do wielokrotnego dopasowania.[16]

Metoda jest dostępna w wersji online na stronie: http://servers.binf.ku.dk/mastr/ oraz jako kod źródłowy do pobrania z: http://servers.binf.ku.dk/mastr/download.php. Formatem wejściowym jest FASTA, a wynikowym PostScript.[48]

Welcome to the MASTR server Multiple Alignment of Structural RNAs									
This webserver performs multiple alignment and secondary structure prediction on a set of structural RNA sequences using the MASTR program. It is hosted by The Bioinformatics Center at the University of Copenhagen in Demnark, Questions, bugs etc. should be emailed to Stimus Lindgreen. To use the MASTR webserver, simply upload your RNA sequences (i.e. at least 2) in FASTA format either as a file or by pasting them into the box below. You will receive an email when the results are ready. If you use this service, please add a reference to our paper: S. Lindgreen, P.P. Gardner and A. Krogh (2007) MASTR: Multiple alignment and structure prediction of non-coding RNAs using simulated annealing. Bioinformatics, 23(24):3304-11 [Link to paper] You can download the source code and various data files here.									
Dataset with RNA sequences (i.e. at least 2) in Fasta format Wybierz plik Mie wybrano pliku Advanced parameters:									
Gap open probability 0.5 Gap extension probability 0.74 Base pairing mult probability 0.23 Scaling factor of basepairing probability 1.5 Scaling factor of log-likelihood 1 Scaling factor of covariation 0.6 Covariation cut-off 0.25 Iteration dependence on alignment size (#nucl.) 700 Iteration dependence on alignment length 2500 Email notification (when done):									

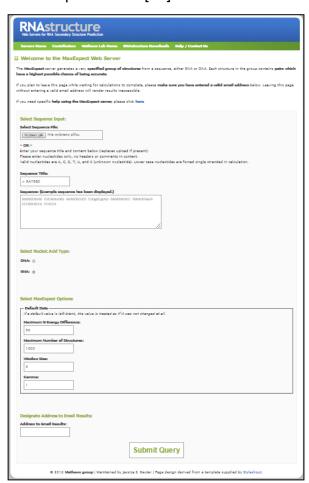
Ryc.17. Strona domyślna MASTR.

MaxExpect

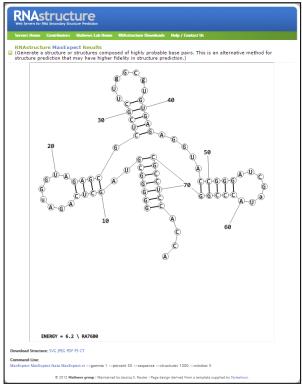
Metoda służąca do przewidywania struktury drugorzędowej RNA w oparciu o maksymalizację oczekiwanej dokładności parowaniu się zasad. Algorytm przewiduje zarówno optymalną strukturę oraz nieoptymalne, które mogą posłużyć jako alternatywa. Średnia dodatnia wartość predykcyjna (PPV) dla MaxExpect jest o 2% większa w porównaniu do algorytmów korzystających z minimalizacji energii swobodnej.[17]

Narzędzie należy do oprogramowania RNAstructure. Dostęp online pod adresem: http://rna.urmc.rochester.edu/RNAstructureWeb/Servers/MaxExpect/MaxExpect.html. Jak również można pobrać całą paczkę wraz z danym narzędziem.

Jako dane wejściowe akceptowany jest format FASTA. Po wykonaniu się zapytania otrzymujemy wyniki w kilku formatach: FASTA, SVG, JPEG, PDF, PostScript oraz CT.[49]



Ryc.18. Strona domyślna MaxExpect.



Ryc.19. Strona wynikowa MaxExpect.

Multialign

PETfold

• strona internetowa: http://rth.dk/resources/petfold/submit.php

PPfold

• strona internetowa: http://www.daimi.au.dk/~compbio/pfold/downloads.html

ProbKnot
RNAalifold
RNA Sampler • strona internetowa: http://stormo.wustl.edu/RNASampler/index.html
RNAshapes
RNASLOpt
RNAwolf • strona internetowa: http://www.tbi.univie.ac.at/software/rnawolf/rnawolf.html • strona internetowa: http://hackage.haskell.org/package/RNAwolf
Sfold • strona internetowa: http://sfold.wadsworth.org/cgi-bin/index.pl
taveRNA
TurboFold

Opcje narzędzi

Nazwa metody	Dostępność	Dostęp	Systemy operacyjne, na których działa	Input	Output	Struktury	Język	Ograniczenia
Afold	darmowe oprogramowanie dostępne dla wszystkich	przez serwer ftp	Linux, Windows	FASTA lub format Genbank	plik "Afold.res"	pętle wewnętrzne	C/C++	do 28 000 nt, min. 2GB RAM
Carnac	darmowe oprogramowanie dostępne dla wszystkich	online (web serwer) lub lokalnie na własnym komputerze	Linux, Windows	FASTA	CT, PostScript, JPEG, dot-bracket, list of stems, archiwum .zip	elementy struktury drugorzędowej rodzin homologicznych niekodującego RNA		do 300 nt (kilka s) do 2000 nt (kilka min)
CentroidFold	darmowe oprogramowanie dostępne dla wszystkich	online	-	FASTA	TEXT, PNG, PDF, EPS	wszystkie elementy struktury drugorzędowej		do 400 nt
CentroidHomfold	darmowe oprogramowanie dostępne dla wszystkich	online	-	FASTA	TEXT, PNG, PDF, EPS	wszystkie elementy struktury drugorzędowej		do 400 nt
ContraFold	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux	FASTA	BPSEQ	wszystkie elementy struktury drugorzędowej	C++	do 1000 nt

Nazwa metody	Dostępność	Dostęp	Systemy operacyjne, na których działa	Input	Output	Struktury	Język	Ograniczenia
DotKnot	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Windows, Linux, Mac OS-X	sekwencja RNA w formacie FASTA	dot-bracket	pseudowęzły	Python	do 1000 nt dla pseudowęzłów typu H do 400 nt dla kissing harpins
HotKnots	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Windows, Linux, Mac OS-X	sekwencja RNA w formacie FASTA lub tekstowym	dot-bracket	pseudowęzły	C/C++	do 500 nt lokalnie do 100 nt online
TurboKnot	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Windows, Linux, Mac OS-X	FASTA	SVG, JPEG, PDF, CT, PostScript	pseudowęzły	C/C++, Java	
CMFinder	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Windows, Linux, Mac OS-X	FASTA	archiwum .zip na podany adres mailowy	motywy		do 60 sekwencji po 500 nt
CRWrnafold	darmowe oprogramowanie dostępne dla wszystkich	online	-	wybór konkretnych informacji	archiwum .zip	spinki, pętle wewnętrzne	C#	brak
CyloFold	darmowe oprogramowanie dostępne dla wszystkich	online	-	FASTA lub Raw Sequence	JPG, dot-bracket, CT	pseudowęzły	C++, Groovy	do 300 nt
Mastr	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux	FASTA	PostScript	odcinki non-coding RNAs	C++	od 70 do 250 nt

Nazwa metody	Dostępność	Dostęp	Systemy operacyjne, na których działa	Input	Output	Struktury	Język	Ograniczenia
MaxExpect	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux, Windows	FASTA	FASTA, SVG, JPEG, PDF, PostScript, CT	wszystkie elementy struktury drugorzędowej		do 3000 nt
Multialign	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux, Windows	FASTA	SVG, JPEG, PDF, PostScript, CT	wspólna struktura drugorzędowa o najniższej energii dla kilku sekwencji	C++	powyżej 1500 nt
PETfold	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	dowolny	FASTA, Newick, notacja dot-bracket	PostScript, PDF, Newick, dotplot file	wszystkie elementy struktury drugorzędowej	Perl	
PPfold	darmowe oprogramowanie dostępne dla wszystkich	lokalnie na własnym komputerze	Linux	FASTA, Newick	CT, pik .seq	wszystkie elementy struktury drugorzędowej	Java 6.0	do ok. 9000 nt
ProbKnot	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Windows, Linux, Mac OS-X	FASTA	SVG, JPEG, PDF, PostScript, CT	pseudowęzły	C++, Java	do ok 3000 nt
RNAalifold	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux	FASTA lub Clustal W	Vienna Format, CT, PDF, EPS, JPG	wszystkie elementy struktury drugorzędowej		
RNA Sampler	darmowe oprogramowanie dostępne dla wszystkich	lokalnie na własnym komputerze	Linux, Windows	FASTA	własny format	wszystkie elementy struktury drugorzędowej	С	

Nazwa metody	Dostępność	Dostęp	Systemy operacyjne, na których działa	Input	Output	Struktury	Język	Ograniczenia
RNAshapes	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux, Windows	FASTA	dot-bracket	wszystkie elementy struktury drugorzędowej	С	do 1500 nt
RNASLOpt	darmowe oprogramowanie dostępne dla wszystkich	lokalnie na własnym komputerze	Linux	sekwencja RNA	optymalne reprezentacje w notacji dot-bracket wraz z ich energiami	wszystkie elementy struktury drugorzędowej		do 250 nt
RNAwolf	darmowe oprogramowanie dostępne dla wszystkich	lokalnie na własnym komputerze	Linux	sekwencja RNA		triplety i niekanoniczne pary zasad	Haskell	
Sfold	darmowe oprogramowanie dostępne dla wszystkich	online	-	FASTA, GenBank	PostScript, PDF, TXT, archiwum .zip	wszystkie elementy struktury drugorzędowej		do 200 nt online, do 5000 nt lokalnie
taveRNA	darmowe oprogramowanie dostępne dla wszystkich	online lub niektóre z narzędzi możliwe do pobrania	Linux	FASTA	CT, PostScript, GIF	wszystkie elementy struktury drugorzędowej	C/C++	do 150 nt dla Stacked Pair Model, do 500 nt dla Loop Models
TurboFold	darmowe oprogramowanie dostępne dla wszystkich	online lub lokalnie na własnym komputerze	Linux, Windows	FASTA	SVG, JPEG, PDF, PostScript, CT	wszystkie elementy struktury drugorzędowej		

Podsumowanie

Bibliografia

- [1] Lubert Stryer *Biochemia* Wydawnictwo Naukowe PWN (1999)
- [2] Suzanne Clancy, Ph.D. Chemical Structure of RNA Nature Education (2008)
- [3] Ronny Lorenz, Michael T. Wolfinger, Andrea Tanzer, Ivo L. Hofacker *Predicting RNA secondary structures from sequence and probing data* Elsevier (2016)
- [4] Aleksey Y. Ogurtsov, Svetlana A. Shabalina, Alexey S. Kondrashov, Mikhail A. Roytberg

Analysis of internal loops within the RNA secondary structure in almost quadratic time Bioinformatics (2006)

- [5] Woods, D.A., Batzoglou, S. CONTRAfold: RNA Secondary Structure Prediction without Energy-Based Models. Bioinformatics (2006)
- [6] Helene Touzet, Olivier Perriquet CARNAC: folding families of related RNAs (2004)
- [7] Kengo Sato, Michiaki Hamada, Kiyoshi Asai, Toutai Mituyama CENTROIDFOLD: a web server for RNA secondary structure prediction (2009)
- [8] Michiaki Hamada, Koichiro Yamada, Kengo Sato, Martin C. Frith, Kiyoshi Asai CentroidHomfold-LAST: accurate prediction of RNA secondary structure using automatically collected homologous sequences (2011)
- [9] Zizhen Yao, Zasha Weinberg, Walter L. Ruzzo CMfinder - a covariance model based RNA motif finding algorithm Bioinformatics (2005)
- [10] David P. Gardner, Pengyu Ren, Stuart Ozer, Robin R. Gutell Statistical Potentials for Hairpin and Internal Loops Improve the Accuracy of the Predicted RNA Structure (2011)
- [11] Eckart Bindewald1, Tanner Kluth, Bruce A. Shapiro *CyloFold: secondary structure prediction including* pseudoknots (2010)
- [12] Kengo Sato, Yuki Kato, Tatsuya Akutsu, Kiyoshi Asai, Yasubumi Sakakibara *DAFS: simultaneous aligning and folding of RNA sequences via dual decomposition* Bioinformatics (2012)
- [13] Jana Sperschneider, Amitava Datta DotKnot: pseudoknot prediction using the probability dot plot under a refined energy model (2010)
- [14] Jihong Ren, Baharak Rastegardi, Anne Condon, Holger H. Hoos

HotKnots: Heuristic prediction of RNA secondary structures including pseudoknots Bioinformatics (2005)

- [15] Kengo Sato, Yuki Kato, Michiaki Hamada, Tatsuya Akutsu, Kiyoshi Asai IPknot: fast and accurate prediction of RNA secondary structures with pseudoknots using integer programming Bioinformatics
- [16] Stinus Lindgreen, Paul P. Gardner, Anders Krogh MASTR: multiple alignment and structure prediction of non-coding RNAs using simulated annealing Bioinformatics (2007)
- [17] Zhi John Lu, Jason W. Gloor, David H. Mathews Improved RNA secondary structure prediction by maximizing expected pair accuracy Bioinformatics (2009)
- [18] Zhenjiang Xu, David H. Mathews Multilign: an algorithm to predict secondary structures conserved in multiple RNA sequences Bioinformatics (2010)
- [19] Hisanori Kiryu, Yasuo Tabei, Taishin Kin, Kiyoshi Asai *Murlet: a practical multiple alignment tool for structural RNA sequences* Bioinformatics (2007)
- [20] Yasuo Tabei, Kiyoshi Asai A local multiple alignment method for detection of non-coding RNA sequences Bioinformatics (2009)
- [21] Stefan E. Seemann, Jan Gorodkin, Rolf Backofen Unifying evolutionary and thermodynamic information for RNA folding of multiple alignments (2008)
- [22] Jens Reeder, Peter Steffen, Robert Giegerich pknotsRG: RNA pseudoknot folding including near-optimal structures and sliding windows (2007)
- [23] Zsuzsanna Sükösd, Bjarne Knudsen, Morten Værum, Jørgen Kjems, Ebbe S Andersen

Multithreaded comparative RNA secondary structure prediction using stochastic context-free grammars BMC Bioinformatics (2011)

- [24] Stanislav Bellaousov, David H. Mathews ProbKnot: Fast prediction of RNA secondary structure including pseudoknots Bioinformatics (2010)
- [25] Xiaomin Ying, Hong Luo, Jingchu Luo, Wuju Li RDfolder: a web server for prediction of RNA secondary structure (2004)
- [26] Stephan H Bernhart, Ivo L Hofacker, Sebastian Will, Andreas R Gruber, Peter F Stadler

RNAalifold: improved consensus structure prediction for RNA alignments

BMC Bioinformatics (2008)

[27] Xing Xu, Yongmei Ji, Gary D. Stormo

RNA Sampler: a new sampling based algorithm for common RNA secondary structure prediction and structural alignment Bioinformatics (2007)

[28] Peter Steffen, Björn Voß, Marc Rehmsmeier, Jens Reeder, Robert Giegerich RNAshapes: an integrated RNA analysis package based on abstract shapes Bioinformatics (2005)

[29] Yuan Li, Shaojie Zhang

Finding stable local optimal RNA secondary structures Bioinformatics (2011)

[30] Jessica S Reuter, David H Mathews

RNAstructure: software for RNA secondary structure prediction and analysis BMC Bioinformatics (2010)

[31] Christian Höner zu Siederdissen, Stephan H. Bernhart, Peter F. Stadler Ivo L. Hofacker

A folding algorithm for extended RNA secondary structures Bioinformatics

[32] Junilda Spirollari, Jason T.L. Wang, Kaizhong Zhang, Vivian Bellofatto2, Yongkyu Park, Bruce A. Shapiro

Predicting Consensus Structures for RNA Alignments Via Pseudo-Energy Minimization (2009)

[33] Ye Ding, Chi Yu Chan, Charles E. Lawrence Sfold web server for statistical folding and rational design of nucleic acids (2004)

[34] Cagri Aksay, Raheleh Salari, Emre Karakoc, Can Alkan, S. Cenk Sahinalp taveRNA: a web suite for RNA algorithms and applications (2007)

[35] Arif O Harmanci, Gaurav Sharma, David H Mathews

TurboFold: Iterative probabilistic estimation of secondary structures for multiple RNA sequences BMC Bioinformatics (2011)

[36] Matthew G. Seetin, David H. Mathews

TurboKnot: rapid prediction of conserved RNA secondary structures including pseudoknots Bioinformatics (2012)

- [37] http://iimcb.genesilico.pl/comparna/methods/
- [38] http://bioinfo.lifl.fr/RNA/carnac/
- [39] http://rtools.cbrc.jp/centroidfold/
- [40] http://rtools.cbrc.jp/centroidhomfold/
- [41] http://contra.stanford.edu/contrafold/
- [42] http://dotknot.csse.uwa.edu.au/
- [43] http://www.cs.ubc.ca/labs/beta/Software/HotKnots/

[44]

http://rna.urmc.rochester.edu/RNAstructureWeb/Servers/TurboFold/TurboFold.html

[45] http://bio.cs.washington.edu/CMfinderWeb/CMfinderInput.pl

- [46] http://www.rna.ccbb.utexas.edu/DAT/3C/Structure/index.php[47] https://cylofold.ncifcrf.gov/cylofold-0.1/sequenceJob/create[48] http://servers.binf.ku.dk/mastr/

- [49]

http://rna.urmc.rochester.edu/RNAstructureWeb/Servers/MaxExpect/MaxExpect.html